

# Proyecto de Gestión de Inventario con IA para XYZ Retail

## Resumen Ejecutivo

### Desafío Empresarial y Oportunidad de la IA

La empresa minorista XYZ enfrenta desafíos significativos debido a niveles de inventario impredecibles, lo que resulta en escasez de productos populares y exceso de existencias de artículos de baja demanda. Esta situación conduce a la pérdida de ventas, clientes insatisfechos, mayores costos de almacenamiento y una eficiencia operativa reducida. La falta de una visibilidad clara sobre las tendencias de la demanda y la fiabilidad de la cadena de suministro agrava estos problemas.

La Inteligencia Artificial (IA), específicamente a través del uso de Modelos de Lenguaje Grandes (LLM) para el análisis de datos y plataformas de automatización como Make.com, presenta una oportunidad estratégica para transformar la gestión de inventario de XYZ. Al aprovechar la IA, XYZ puede obtener una comprensión más profunda de los patrones de demanda, optimizar los niveles de stock, automatizar los procesos de reabastecimiento y mitigar los riesgos de la cadena de suministro.

### Descripción General de la Solución de IA Propuesta y sus Beneficios Esperados

La solución propuesta se centra en un enfoque híbrido que combina el análisis de datos impulsado por LLM con la automatización basada en reglas. Los componentes clave incluyen:

1. **Análisis de Datos con LLM:** Utilización de LLM para procesar grandes volúmenes de datos de ventas históricos (ORDERNUMBER, QUANTITYORDERED, PRICEEACH, ORDERDATE, PRODUCTLINE, COUNTRY, STATUS) y extraer insights cualitativos sobre tendencias de demanda, estacionalidad y patrones de compra por línea de producto y ubicación geográfica. El LLM identificará patrones significativos sin realizar predicciones numéricas complejas.
2. **Sistema de Alertas Basado en Reglas:** Desarrollo de un conjunto de reglas de negocio dinámicas, informadas por los insights del LLM, para activar alertas de inventario. Estas reglas considerarán factores como la línea de producto, el precio y el país del cliente.
3. **Automatización con Make.com:** Implementación de un flujo de trabajo en Make.com que ingiera datos de ventas, aplique las reglas de alerta definidas y, al activarse una regla, genere notificaciones automáticas a los gerentes de inventario y simule solicitudes de reabastecimiento a proveedores.
4. **Evaluación de Riesgos:** Un marco para evaluar y mitigar riesgos asociados con interrupciones de la cadena de suministro (considerando STATUS y COUNTRY), la

precisión de las reglas de alerta y el cumplimiento normativo.

### **Beneficios Esperados:**

- **Reducción de Escasez y Exceso de Existencias:** Al anticipar mejor la demanda y reaccionar rápidamente a los cambios.
- **Optimización de Costos de Inventario:** Disminución de los costos de almacenamiento y reducción de pérdidas por obsolescencia.
- **Mejora de la Eficiencia Operativa:** Automatización de tareas manuales repetitivas, liberando al personal para actividades de mayor valor.
- **Mayor Satisfacción del Cliente:** Garantizando la disponibilidad de productos clave.
- **Toma de Decisiones Basada en Datos:** Proporcionando insights claros y accionables sobre el comportamiento del inventario y la demanda.

### **Plan de Implementación de Alto Nivel**

1. **Fase 1: Preparación y Análisis (Semanas 1-3)**
  - **Recopilación y Limpieza de Datos:** Asegurar el acceso al dataset de ventas de ClassicModels y realizar cualquier preprocesamiento necesario.
  - **Análisis Inicial con LLM:** Alimentar los datos de ventas al LLM para identificar tendencias, estacionalidad y patrones de compra.
  - **Formulación de Reglas:** Basarse en los insights del LLM para definir las reglas de alerta de inventario.
2. **Fase 2: Desarrollo y Prototipo (Semanas 4-6)**
  - **Diseño del Flujo de Make.com:** Crear el diseño lógico del flujo de trabajo de Make.com para la ingesta de datos, la aplicación de reglas y las acciones de alerta/reabastecimiento.
  - **Implementación del Prototipo de Make.com:** Configurar los módulos y conexiones en Make.com (simulando integraciones si es necesario).
  - **Desarrollo del Prototipo de Alerta:** Crear una interfaz simple (como el prototipo HTML/JS que se muestra más adelante) para visualizar las alertas generadas.
3. **Fase 3: Pruebas y Evaluación (Semanas 7-8)**
  - **Pruebas del Flujo de Make.com:** Realizar pruebas exhaustivas del flujo de trabajo con datos de muestra para asegurar que las alertas se disparen correctamente.
  - **Evaluación de Riesgos:** Revisar y documentar los factores de riesgo identificados y las estrategias de mitigación.
  - **Definición de Métricas de Éxito:** Establecer líneas base para las métricas de éxito y planificar la recopilación de datos post-implementación.

#### 4. Fase 4: Despliegue y Monitoreo (Semanas 9 en adelante)

- **Despliegue Piloto:** Implementar la solución en un entorno controlado o con un subconjunto de productos.
- **Monitoreo y Ajuste:** Monitorear continuamente el rendimiento, recopilar feedback y ajustar las reglas o el flujo de trabajo según sea necesario.
- **Escalado:** Expandir la solución a más productos y categorías una vez que se demuestre su efectividad.

## Informe de Estrategia de IA

### Estrategia de Datos

Fuentes de Datos:

La fuente de datos principal para este proyecto es el dataset de ventas de ClassicModels, accesible a través de Kaggle. Este dataset contiene información crítica para el análisis de inventario:

- **ORDERNUMBER:** Identificador único de cada pedido.
- **QUANTITYORDERED:** Cantidad de un producto en un pedido.
- **PRICEEACH:** Precio unitario de un producto en el momento de la venta.
- **ORDERDATE:** Fecha en que se realizó el pedido, crucial para el análisis de tendencias temporales.
- **PRODUCTLINE:** Categoría general del producto (ej., "Motorcycles", "Planes").
- **PRODUCTCODE:** Código específico del producto.
- **COUNTRY:** País del cliente, importante para el análisis geográfico y de riesgos.
- **STATUS:** Estado del envío del pedido, relevante para la evaluación de riesgos de la cadena de suministro.

### Consideraciones de Calidad de Datos:

- **Compleitud:** Verificar que no haya valores nulos o faltantes en campos clave como QUANTITYORDERED, ORDERDATE, PRODUCTLINE.
- **Consistencia:** Asegurar que los formatos de fecha sean uniformes y que las PRODUCTLINE se escriban de manera consistente.
- **Precisión:** Validar que los QUANTITYORDERED y PRICEEACH reflejen valores realistas y que no haya errores de entrada.
- **Actualidad:** Para una implementación real, se necesitaría un flujo continuo de datos de ventas actualizados.

### Pasos de Preprocesamiento:

1. **Carga de Datos:** Importar el dataset a un formato manejable (CSV, base de datos).
2. **Manejo de Valores Faltantes:** Imputar o eliminar filas con datos faltantes,

dependiendo del impacto.

3. **Conversión de Tipos de Datos:** Asegurar que ORDERDATE esté en formato de fecha/hora y que QUANTITYORDERED y PRICEEACH sean numéricos.
4. **Creación de Campos Derivados (Opcional pero útil):**
  - SALES: Calcular QUANTITYORDERED \* PRICEEACH para obtener el valor total de la venta por ítem.
  - MONTH, QUARTER, YEAR: Extraer componentes de la fecha para análisis de estacionalidad.

## Modelo de IA o Elección de Automatización

La solución propuesta no se basa en un modelo de IA predictivo complejo, sino en la **combinación estratégica de LLM para la extracción de insights cualitativos y Make.com para la automatización basada en reglas.**

### Por qué y cómo la solución aborda el desafío empresarial:

- **Herramientas de LLM (para Análisis de Datos):**
  - **Por qué:** Los LLM son excelentes para procesar texto y datos semiestructurados, identificar patrones, resumir información y extraer relaciones complejas que podrían no ser evidentes en un análisis puramente estadístico. En este proyecto, su rol es actuar como un "analista de datos inteligente" que puede digerir el dataset de ventas y señalar tendencias clave en lenguaje natural.
  - **Cómo:** El LLM sería alimentado con el dataset de ventas (posiblemente después de una conversión a un formato legible por texto, como CSV o JSON). Se le pediría que identificara:
    - Productos más vendidos y categorías más populares (PRODUCTLINE, QUANTITYORDERED).
    - Fluctuaciones de la demanda a lo largo del tiempo (ORDERDATE, QUANTITYORDERED).
    - Patrones de compra estacionales (ej., "Motorcycles" en verano).
    - Relaciones entre COUNTRY y PRODUCTLINE en términos de demanda.
    - Anomalías o picos inusuales en las ventas.
  - **Ejemplo de interacción con LLM (simulado):**
    - **Usuario:** "Analiza este dataset de ventas y dime cuáles son las líneas de producto más populares, si hay estacionalidad en la demanda y si observas algún patrón de compra por país."
    - **Respuesta del LLM (simulado):** "Basado en los datos, la línea de producto 'Motorcycles' es consistentemente la más vendida, seguida de 'Classic Cars'. Se observa una clara estacionalidad para 'Motorcycles', con

picos de demanda en los meses de primavera y verano (Marzo-Agosto). Para 'Classic Cars', la demanda es más constante. En cuanto a patrones geográficos, 'USA' y 'France' son los países con mayor volumen de pedidos, y 'Motorcycles' son especialmente populares en 'USA', mientras que 'Ships' tienen una demanda notable en 'Australia'."

- **Make.com (para Automatización Basada en Reglas):**

- **Por qué:** Make.com es una plataforma de automatización sin código/bajo código que permite conectar diferentes aplicaciones y servicios para crear flujos de trabajo complejos. Es ideal para implementar el sistema de alertas y la simulación de reabastecimiento, ya que puede programar tareas, aplicar lógica condicional y enviar notificaciones.
- **Cómo:** Make.com actuaría como el orquestador. Recopilaría datos (simuladamente del dataset o de una fuente real), aplicaría las reglas definidas (basadas en los insights del LLM) y ejecutaría acciones.

- **Flujo de Trabajo Típico en Make.com:**

1. **Trigger (Disparador):** Podría ser un horario (ej., cada día, cada semana) para procesar nuevos datos de ventas, o un webhook si los datos se actualizan en tiempo real.
2. **Módulo de Datos:** Cargar los datos de ventas más recientes (simulado como una lectura de un archivo CSV o una base de datos).
3. **Módulo de Procesamiento/LLM (Simulado):** Aunque Make.com no tiene un módulo LLM nativo para este tipo de análisis, se podría simular que los insights del LLM ya han sido pre-calculados y que Make.com simplemente aplica reglas basadas en esos insights. Para una integración real, se podría usar un módulo HTTP para llamar a una API de LLM.
4. **Módulo de Filtro/Router:** Aplicar las reglas de negocio definidas. Por ejemplo:
  - Si PRODUCTLINE == "Motorcycles" Y COUNTRY == "USA" Y QUANTITYORDERED > 50 en la última semana, entonces...
  - Si el inventario de PRODUCTCODE X cae por debajo de Y unidades, entonces... (Esto requeriría un módulo de inventario real o simulado).
5. **Módulo de Acción (Alertas):** Si una regla se activa, enviar una notificación. Esto podría ser un correo electrónico (módulo de Gmail/Outlook), un mensaje de Slack/Teams, o una entrada en una hoja de cálculo.
6. **Módulo de Acción (Reabastecimiento Simulado):** Generar una "solicitud de reordenamiento". Esto podría ser un registro en una base

de datos, una entrada en un CRM, o un correo electrónico a un proveedor simulado.

## Viabilidad de la Implementación

### Requisitos:

- **Datos:** Acceso continuo y fiable a datos de ventas históricos y actuales.
- **Herramientas:**
  - Acceso a una plataforma LLM (ej., Google Gemini API, OpenAI GPT, etc.) para el análisis de datos.
  - Una cuenta de Make.com (o una plataforma similar de automatización).
  - Conocimientos básicos de manipulación de datos (CSV, JSON).
- **Personal:**
  - Analistas de datos para el preprocesamiento y la validación de datos.
  - Expertos en el negocio (gerentes de inventario) para validar insights y definir reglas.
  - Desarrolladores o integradores para configurar Make.com y posibles APIs.

### Riesgos:

- **Calidad de Datos:** Datos inconsistentes o incompletos pueden llevar a insights erróneos y alertas imprecisas.
- **Precisión del LLM:** Aunque los LLM son potentes, pueden generar "alucinaciones" o interpretaciones incorrectas si no se les guía adecuadamente o si los datos son ambiguos.
- **Complejidad de Reglas:** Un exceso de reglas o reglas demasiado complejas pueden ser difíciles de mantener y depurar.
- **Dependencia de Make.com:** La estabilidad y el costo de la plataforma Make.com son factores a considerar.
- **Integración:** La integración con sistemas existentes (ERP, sistemas de inventario) puede ser compleja si no se dispone de APIs adecuadas.
- **Resistencia al Cambio:** El personal puede resistirse a confiar en un sistema automatizado.

### Recursos Necesarios:

- **Financieros:** Costos de licencias de LLM (si aplica), suscripción a Make.com, costos de almacenamiento de datos.
- **Tecnológicos:** Infraestructura para el almacenamiento y procesamiento de datos, herramientas de integración.
- **Humanos:** Equipo multidisciplinar (negocio, datos, IT).

## Evaluación Ética y de Cumplimiento

## Sesgo de la IA:

- **Riesgo:** Si los datos históricos de ventas reflejan sesgos (ej., promociones pasadas que favorecieron ciertos productos artificialmente, o datos incompletos de ciertos mercados), el LLM podría identificar patrones que no son representativos de la demanda real o futura. Esto podría llevar a reglas de alerta que perpetúen esos sesgos, causando escasez o exceso de existencias en categorías o regiones específicas.
- **Mitigación:**
  - **Auditoría de Datos:** Realizar auditorías regulares del dataset para identificar y corregir posibles sesgos en la recopilación de datos.
  - **Validación Humana:** Los insights del LLM y las reglas derivadas deben ser revisados y validados por expertos en el negocio para asegurar que sean lógicos y justos.
  - **Monitoreo Continuo:** Monitorear el rendimiento del sistema de alertas en diferentes líneas de producto y geografías para detectar y corregir cualquier impacto desproporcionado.

## Transparencia:

- **Riesgo:** Si las reglas de alerta y las decisiones de reabastecimiento son vistas como una "caja negra", los empleados pueden desconfiar del sistema y no utilizarlo eficazmente.
- **Mitigación:**
  - **Documentación Clara:** Documentar explícitamente cómo se derivaron los insights del LLM y cómo se formularon las reglas de alerta.
  - **Explicabilidad:** Asegurarse de que las razones detrás de una alerta específica sean comprensibles (ej., "Alerta activada porque las ventas de 'Motorcycles' en 'USA' superaron el umbral de 50 unidades esta semana").
  - **Capacitación:** Capacitar al personal sobre cómo funciona el sistema, cómo interpretar las alertas y cómo se espera que interactúen con él.

## Privacidad de Datos (si aplica):

- **Riesgo:** Aunque el dataset de ClassicModels no contiene información personal sensible de clientes, en un escenario real, los datos de ventas podrían vincularse a información de clientes. El uso de LLM implica enviar datos a un servicio externo, lo que plantea preocupaciones sobre la privacidad y la seguridad de los datos.
- **Mitigación:**
  - **Anonimización/Pseudonimización:** Si se utilizan datos de clientes reales, anonimizar o pseudonimizar la información personal antes de alimentarla a los



LLM o a Make.com.

- **Cumplimiento Normativo:** Asegurarse de que todas las prácticas de manejo de datos cumplan con las regulaciones de privacidad de datos relevantes (ej., GDPR, CCPA).
- **Acuerdos de Procesamiento de Datos (DPA):** Establecer DPAs con los proveedores de servicios de LLM y Make.com para garantizar que manejen los datos de forma segura y conforme a la ley.
- **Seguridad de Datos:** Implementar medidas de seguridad robustas para proteger los datos en tránsito y en reposo.

## Informe de Análisis de Datos e Insights (Simulado con LLM)

Este informe presenta un resumen de los insights clave que un Modelo de Lenguaje Grande (LLM) podría extraer del dataset de ventas de ClassicModels. El enfoque está en identificar patrones y tendencias claras, sin la necesidad de modelos predictivos complejos.

**Dataset Analizado:** Datos de ventas de ClassicModels (campos clave: ORDERNUMBER, QUANTITYORDERED, PRICEEACH, ORDERDATE, PRODUCTLINE, PRODUCTCODE, COUNTRY, STATUS).

### Resumen de Insights Clave Obtenidos del Análisis de LLM:

- Productos Más Vendidos y Categorías Más Populares (PRODUCTLINE, QUANTITYORDERED):**
  - El LLM identificaría consistentemente que la línea de producto "**Motorcycles**" es, con diferencia, la más popular y la que genera el mayor volumen de ventas en términos de QUANTITYORDERED.
  - Le sigue de cerca "**Classic Cars**", que también muestra un rendimiento robusto.
  - Otras líneas como "Planes", "Ships" y "Trains" tienen una demanda menor pero estable.
  - **Insight:** La estrategia de inventario debe priorizar "Motorcycles" y "Classic Cars" debido a su alta demanda.
- Fluctuaciones de la Demanda a lo Largo del Tiempo (ORDERDATE, QUANTITYORDERED):**
  - El LLM detectaría una **clara estacionalidad en la demanda de "Motorcycles"**. Específicamente, la demanda tiende a ser significativamente mayor durante los meses de **primavera y verano (aproximadamente de marzo a agosto)**. Esto sugiere un patrón de compra relacionado con el clima y las actividades al aire libre.



- Para "Classic Cars", la demanda es más **consistente a lo largo del año**, con menos fluctuaciones estacionales pronunciadas.
  - Se podrían identificar **picos de demanda específicos** en ciertos meses o alrededor de festividades, que el LLM podría señalar como "eventos de alta demanda".
  - **Insight:** Es crucial aumentar el stock de "Motorcycles" antes de la temporada de primavera/verano y mantener un nivel de stock más constante para "Classic Cars".
3. **Patrones de Compra por Ubicación Geográfica (COUNTRY):**
- El LLM señalaría que **"USA" y "France"** son los países que generan el mayor volumen de pedidos y ventas.
  - Se podría observar que ciertas líneas de producto tienen una popularidad desproporcionada en países específicos; por ejemplo, una demanda particularmente alta de "Motorcycles" en "USA", o de "Ships" en "Australia".
  - **Insight:** Las reglas de alerta de inventario deben considerar la demanda específica por país para optimizar la distribución geográfica del stock.
4. **Fiabilidad de los Proveedores / Impacto del Estado del Envío (STATUS):**
- Aunque el dataset no proporciona datos directos de "proveedores", el campo STATUS puede ser analizado por el LLM para identificar patrones en los estados de los pedidos. Por ejemplo, si un alto porcentaje de pedidos de un PRODUCTCODE particular tienen un STATUS de "On Hold" o "Disputed", el LLM podría inferir una posible interrupción o problema en la cadena de suministro para ese producto.
  - **Insight:** Monitorear los productos con un STATUS problemático puede ayudar a anticipar posibles escaseces y evaluar la fiabilidad implícita de la cadena de suministro para esos ítems.

### **Simplicidad del Análisis y Claridad de los Resultados:**

El análisis del LLM se centra en la identificación de patrones y tendencias de alto nivel que son fácilmente comprensibles y accionables para los gerentes de inventario. No se busca la creación de modelos predictivos numéricos complejos, sino la extracción de "conocimiento" del dataset de una manera intuitiva. Los resultados son cualitativos y descriptivos, lo que facilita su interpretación y la formulación de reglas de negocio claras.

### **Prototipo de Automatización de IA (Descripción de Make.com y Prototipo HTML/JS)**

Dado que no puedo interactuar directamente con Make.com, proporcionaré una

descripción detallada de cómo se implementaría el flujo de trabajo allí, y luego un prototipo HTML/JS que simula el **resultado** de dicho flujo de trabajo: un sistema de alertas de inventario.

### **Prototipo de Flujo de Trabajo de Make.com**

El objetivo de este flujo de trabajo es automatizar las alertas de inventario y simular la reordenación de proveedores basándose en las reglas definidas a partir del análisis del LLM.

**Nombre del Escenario en Make.com:** Gestión de Inventario Inteligente XYZ

#### **Descripción del Flujo:**

1. **Módulo 1: Disparador (Scheduler)**
  - **Tipo:** Scheduler (Programador)
  - **Configuración:** Se ejecuta Cada Día o Cada Semana (según la frecuencia deseada para el análisis y las alertas).
  - **Propósito:** Iniciar el flujo de trabajo para procesar los datos de ventas más recientes.
  - **[Captura de Pantalla: Módulo Scheduler en Make.com]**
2. **Módulo 2: Obtener Datos de Ventas (Google Sheets - Watch New Rows)**
  - **Tipo:** Google Sheets -> Watch New Rows
  - **Configuración:** Conectado a la hoja de cálculo de ventas (simulando el dataset ClassicModels).
  - **Propósito:** Cargar los datos de ventas del periodo más reciente para su análisis.
  - **[Captura de Pantalla: Módulo Google Sheets en Make.com]**
3. **Módulo 3: Procesamiento de Datos y Aplicación de Reglas (Iterator y Router/Filters)**
  - **Tipo:** Tools -> Iterator (para procesar cada fila de datos) y Flow Control -> Router con Filter (para aplicar las reglas).
  - **Configuración:**
    - **Iterator:** Recorre cada registro de venta obtenido en el Módulo 2.
    - **[Captura de Pantalla: Módulo Iterator en Make.com]**
    - **Desafío y Solución Adoptada:** Inicialmente, se intentó que el Iterator pasara los campos de datos individuales (PRODUCTLINE, COUNTRY, QUANTITYORDERED, STATUS) para que un Router o Filter subsiguiente pudiera usarlos directamente para construir mensajes estructurados en Telegram. Sin embargo, se observó un comportamiento inesperado en Make.com donde el Iterator concatenaba todos los datos en un único

campo Value (o un campo similar), haciendo imposible el filtrado y la construcción de mensajes detallados por campos individuales en módulos posteriores como Telegram.

- **[Captura de Pantalla: Output del Iterator mostrando datos concatenados en 'Value']**
- Debido a esta limitación, se optó por una solución pragmática: el flujo en Make.com se configuró para enviar un mensaje básico a Telegram, confirmando la activación de la alerta, pero la visualización detallada de las alertas y sus datos se delega al **"Simulador de Alertas de Inventario"** en el panel HTML/JS. Esto permite cumplir con el requisito de automatización de alertas, mientras que la interfaz web proporciona la riqueza de información necesaria para el usuario final.
- **Filtros (Reglas de Alerta - Ejemplos basados en insights del LLM):**
  - **Regla 1: Alerta de Alta Demanda de Motorcycles en USA**
    - **Condición:** {{2.PRODUCTLINE}} (Producto) Equal to "Motorcycles" AND {{2.COUNTRY}} (País) Equal to "USA" AND {{2.QUANTITYORDERED}} (Cantidad) Greater than X (donde X es un umbral definido, ej., 50 unidades en un periodo).
    - **Propósito:** Identificar picos de demanda para productos clave en mercados específicos.
  - **Regla 2: Alerta de Baja Demanda / Exceso de Existencias Potencial**
    - **Condición:** {{2.PRODUCTLINE}} (Producto) Equal to "Trains" AND {{2.QUANTITYORDERED}} (Cantidad) Less than Y (donde Y es un umbral bajo, ej., 5 unidades en un periodo).
    - **Propósito:** Identificar productos con ventas muy bajas que podrían llevar a exceso de existencias.
  - **Regla 3: Alerta de Problema de Envío Potencial**
    - **Condición:** {{2.STATUS}} (Estado) Equal to "On Hold" OR {{2.STATUS}} (Estado) Equal to "Disputed"
    - **Propósito:** Identificar pedidos con problemas que podrían indicar interrupciones en la cadena de suministro.
- **[Captura de Pantalla: Configuración de Filters/Router en Make.com con las reglas]**

- **Propósito:** Evaluar cada registro de venta contra las reglas de negocio definidas. Si una regla se cumple, el flujo continúa por esa rama.

#### 4. **Módulo 4: Notificación de Alerta (Telegram)**

- **Tipo:** Telegram Bot -> Send a Text Message
- **Configuración:** Conectado a un bot de Telegram y un chat ID.

- **Mensaje:** ¡ALERTA DE INVENTARIO ACTIVADA! Revise el panel interactivo para más detalles. (Debido a las limitaciones mencionadas, el mensaje es genérico, pero confirma la activación).
- **Propósito:** Enviar una notificación inmediata al gerente de inventario cuando se detecta una situación que requiere atención.
- **[Captura de Pantalla: Módulo Telegram en Make.com con configuración de mensaje]**
- **[Captura de Pantalla: Ejemplo de mensaje recibido en Telegram]**
- 5. **Módulo 5: Simulación de Solicitud de Reordenamiento (Google Sheets)**
  - **Tipo:** Google Sheets -> Add a Row
  - **Configuración:** Conectado a una hoja de cálculo llamada Solicitudes de Reordenamiento.
  - **Columnas:** PRODUCTCODE, QUANTITYORDERED, ORDERDATE, RazonAlerta, Estado (ej., "Pendiente de revisión").
  - **Propósito:** Registrar o simular el inicio de un proceso de reordenamiento basado en la alerta.
  - **[Captura de Pantalla: Módulo Google Sheets para reordenamiento simulado en Make.com]**

Capturas de Pantalla / Demostración (Simulada):

En una presentación real, aquí se incluirían capturas de pantalla del escenario de Make.com, mostrando los módulos conectados y las configuraciones de los filtros y acciones. También se podría mostrar un correo electrónico de alerta o una entrada en una hoja de cálculo de Google Sheets como prueba de la automatización.

### **Prototipo HTML/JS de Sistema de Alertas de Inventario y Asistente IA**

Este prototipo es una aplicación web simple que simula cómo se verían las alertas generadas por el sistema de Make.com y demuestra la interacción con un LLM (Gemini).

### **[Captura de Pantalla: Vista general del Panel Interactivo HTML/JS]**

1. **Simulador de Alertas de Inventario:**
  - **Descripción:** Permite al usuario hacer clic en un botón para "cargar" alertas simuladas. Estas alertas se generan en el frontend (JavaScript) basándose en las mismas reglas de negocio que se aplicarían en Make.com.
  - **Propósito:** Visualizar de forma interactiva el resultado esperado de la automatización de Make.com, mostrando los datos detallados de cada alerta (producto, país, cantidad, tipo de alerta). Esto compensa la limitación de Telegram al no poder volcar datos estructurados.
  - **[Captura de Pantalla: Sección "Simulador de Alertas de Inventario" con**

**alertas cargadas]**

## 2. Asistente de IA (Gemini):

- **Descripción:** Un chatbot integrado directamente en el panel web que permite al usuario hacer preguntas sobre los datos de ventas simulados o sobre conceptos generales de inventario. La respuesta es generada por el modelo Gemini.
- **Propósito:** Demostrar el potencial de un LLM para proporcionar insights conversacionales y asistencia en tiempo real, directamente en una interfaz de usuario.
- **Desafío y Solución Adoptada:** Inicialmente, la llamada a la API de Gemini fallaba con un error 403 (PERMISSION\_DENIED) indicando que no había una identidad de consumidor de API establecida. Aunque en el entorno de Canvas la apiKey debería inyectarse automáticamente, esto no ocurrió. La solución fue obtener una clave de API personal de Google AI Studio y pegarla directamente en el código JavaScript del archivo `interactive_inventory_ai_report.html`. Esto resolvió el problema, permitiendo que el asistente se comunicara exitosamente con la API de Gemini.
- **[Captura de Pantalla: Sección "Asistente de IA (Gemini)" con una pregunta y respuesta]**

## Dataset Recomendado: Dataset de Ventas Proporcionado (Adaptado de ClassicModels)

**Enlace:** [Kaggle Dataset](#) (referencia al dataset original)

**Descripción:** Este dataset contiene datos de ventas de la empresa ClassicModels, incluye información sobre los productos vendidos, las fechas de venta, los precios, las cantidades y los clientes.

**Campos clave:** ORDERNUMBER, QUANTITYORDERED, PRICEEACH, ORDERDATE, PRODUCTLINE, PRODUCTCODE, COUNTRY, STATUS.

**Aplicación:** Se utiliza este dataset (simulado en el frontend) para el análisis de la demanda, la optimización del inventario y la identificación de patrones de compra.